IT4931 · Lưu trữ và xử lý dữ liệu lớn

Phân tích giao dịch tài chính và phát hiện gian lận thời gian thực trên nền tảng Big Data

GVHD: Nguyễn Thị Trang

Nguồn dữ liệu: luồng Internet trực tiếp + Fraud Injector

98%

giao dịch thật từ Binance / Blockchain WebSocket

2%

mẫu gian lận do Fraud Injector tiêm, có nhãn

Real-time

luồng liên tục, không phải file tĩnh

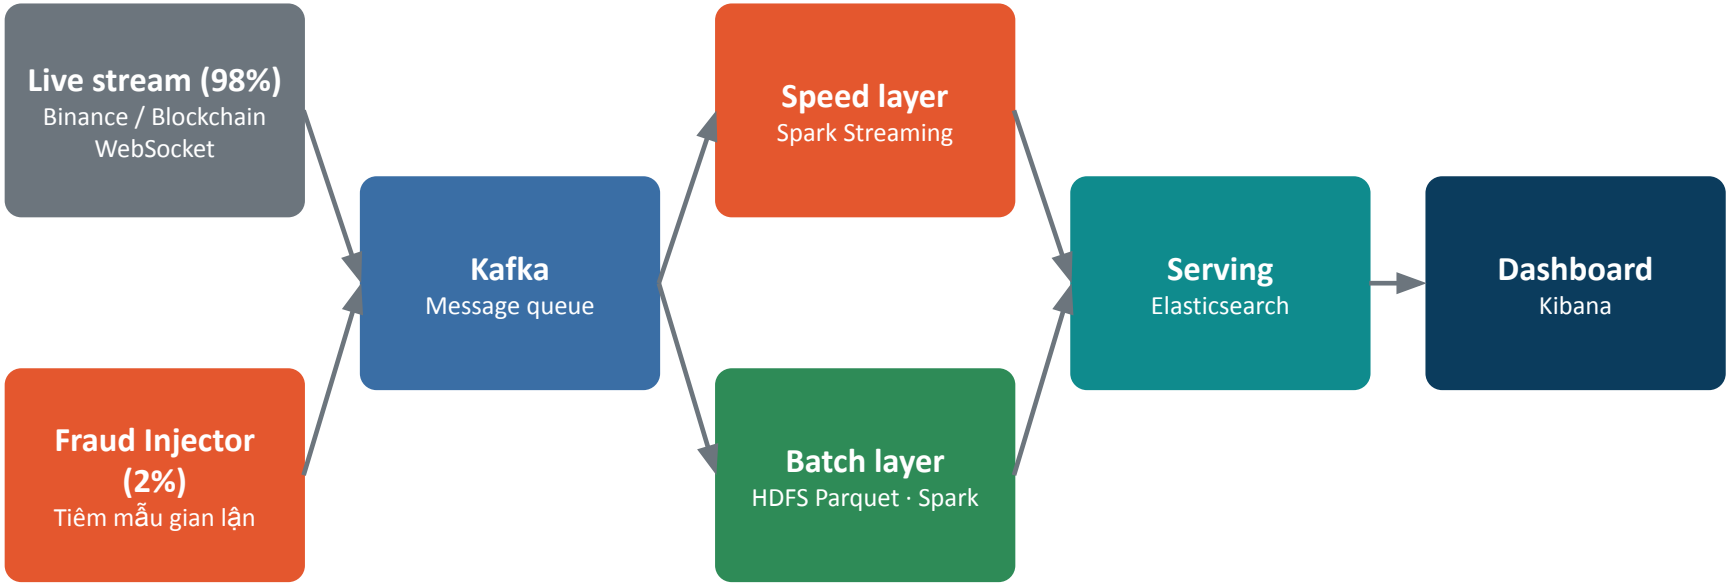
Schema thống nhất trên Kafka topic

- event_id, timestamp – định danh và thời điểm sự kiện
- source – binance | blockchain | injector
- sender, receiver – địa chỉ ví hoặc cặp giao dịch
- amount, price – giá trị / khối lượng
- type – loại sự kiện
- is_injected, fraud_pattern – nhãn ground-truth

Nguồn dữ liệu dự phòng

Dataset PaySim: Kaggle
Gồm 6.5 triệu bản ghi giao dịch
Trong đó: 0.13% là giao dịch gian lận
Ưu điểm: Sẵn có, dễ dàng sử dụng
Nhược điểm: Không mô phỏng được live data, cần giả lập streaming

Kiến trúc Lambda tổng thể



Kafka tách nguồn sinh dữ liệu khỏi hệ thống phân tích; nhãn is_injected cho phép đo độ chính xác phát hiện.

Xử lý và phân tích dữ liệu

Speed layer – phát hiện tức thời

- Giá trị hoặc khối lượng lớn bất thường so với ngưỡng
- Tần suất bùng nổ của một địa chỉ trong cửa sổ trượt 3–5 phút
- Chia nhỏ hoặc chuyển tiếp nhanh qua nhiều địa chỉ
- Gắn cờ cảnh báo, ghi xuống Serving và đối chiếu nhãn is_injected

Batch layer – phân tích định kỳ

- Thống kê luồng giao dịch theo giờ và theo nguồn
- Tỷ lệ cảnh báo theo từng mẫu gian lận
- Precision / recall của luật trên dữ liệu lịch sử
- Cập nhật ngưỡng cảnh báo (ví dụ theo percentile)

Lưu trữ và trực quan hóa

Lưu trữ

- HDFS: luồng sự kiện thô và phân vùng theo thời gian, định dạng Parquet, có thể replay
- Elasticsearch: real-time view và batch view
- Đánh chỉ mục nhanh, truy vấn độ trễ mili-giây

Dashboard (Kibana / Grafana)

- Thông lượng hệ thống theo thời gian thực (TPS)
- Số lượng và danh sách cảnh báo vừa phát hiện
- Precision / recall theo thời gian thực
- Top địa chỉ có hành vi đáng ngờ

Triển khai và kiểm thử hạ tầng

Kubernetes

- Cụm nhiều node K3s hoặc Minikube

Scalability

- Tăng tải bằng nhiều symbol và replay từ HDFS
- Đo thông lượng và độ trễ
- Scale-out Spark worker và Kafka consumer

Fault-tolerance

- Tắt một worker node hoặc Kafka broker khi đang stream
- Kiểm tra hệ thống chạy liên tục
- Không mất dữ liệu

Lưu ý khi dùng nguồn live + injector

Điểm mạnh

- Dữ liệu thật, liên tục, đúng bản chất streaming
- Có nhãn ground-truth để đo precision/recall
- TPS thật, dễ demo scale và fault

Cần xử lý

- Binance/Blockchain không có số dư tài khoản: bỏ luật số dư kiểu PaySim
- Phụ thuộc Internet và giới hạn kết nối: ghi stream vào HDFS để replay khi test
- 2% cao hơn thực tế: nêu rõ là dữ liệu tổng hợp để đánh giá
- Chuẩn hóa hai nguồn về một schema chung trước khi vào Kafka
- Mô tả đúng phạm vi: sự kiện công khai, không phải giao dịch ngân hàng